

Physics-Grounded Driving Policy via MPPI Label Mining




대규모 병렬 물리 시뮬레이션의 최적 제어를, 실시간 주행 정책으로 증류한다. Blender ↔ Genesis sim2sim 정합 → MPPI 골든 라벨 채굴 → BC Mapper 지도학습 → BC freeze + Residual PPO → 외란 복구 강화학습까지의 전 과정 정리.



매 스텝 2048개의 후보 미래를 병렬 물리로 시뮬레이션하고, 최적 궤적 하나를 선택해 지형을 주행하는 MPPI — 반투명 고스트는 컨트롤러가 "상상한" 미래들.

전체 파이프라인

자율주행 경로 추종 제어를 물리적으로 실현 가능한(physically feasible) 데이터로 학습한다.



단계	역할
1. Reference 생성	Blender 표준 지형 위 순수 물리 주행 궤적 추출 — kinematic 이식 배제
2. 골든 라벨 채굴	MPPI 가 2048 병렬 env 로 reference 를 재추종 → 전문가 라벨 (T, S)
3. BC Mapper 학습	라벨 지도학습 → 단일 신경망 추론만으로 실시간 추종
4. Residual RL	BC freeze + PPO 잔차 보정, brake 추가 → (S, T, B) 완전 제어
5. 외란 강건화	외란 주입 학습 + Recovery Policy → OOD 복구 능력

학습 라벨이 이상적 궤적이 아니라 **물리 응답**(경사 등판·하중 이동·타이어 슬립)을 담고 있어, 험지·비정형 지형에서의 일반화를 겨냥한다. 현재의 Blender→Genesis 정합 방법론은 그대로 Real2Sim→Sim2Real 전이 루프의 리허설이 된다.

1. Sim2Sim 정합 — Blender ↔ Genesis



두 물리 세계를 "API 단위"에서 맞춘다: 좌표계·시간 스텝(48Hz)·지형 mesh·차량 파라미터 정합

1.1 역할 분담

	Blender	Genesis
목적	Data-driven physics — ground-truth 생성기	Goal-driven control — 정책 학습 환경
주행 방식	RBC Rig Car 가 guide path 를 물리로 추종	policy 가 매 프레임 (T, S) 직접 생성
추출 데이터	6DoF state·바퀴 토크·steering·모든 프레임의 물리량	학습된 정책의 closed-loop 주행

- Blender 에 가상 센서를 만들어 매 프레임 선속도·각속도·토크·조향각을 추출
- 두 환경 모두 "조향 + 가속 입력" 이라는 동일 인터페이스 유지 → 포맷이 어긋나면 policy 전이가 무너짐



1.2 차량 설계 — URDF

reference 차량 (Blender)	초기 box URDF	현재 차량 (Genesis 이식)
		

좌: Blender reference 차량 / 중: URDF 차체+바퀴+Joint 구조 검증용 box 차량 / 우: 차량 mesh 를 URDF 로 변환해 Genesis 에 이식한 현재 차량

구성	정의
base_link (차체)	box geometry + collision 히트박스 + 질량·관성(inertial)
wheel_fl/fr/rl/rr	cylinder, 90° 회전 배치 — 반지름·두께·마찰 정의
drive joint	4바퀴 continuous — 토크(throttle) 입력
steering	앞바퀴 조향각 입력 — 이후 차량에서 조향 joint 로 확장

- 시작은 단순 box URDF 로 Genesis 에서 "굴리는 것"부터 검증 → 이후 Blender 차량 mesh 를 URDF 로 변환해 이식
- 제어 인터페이스는 처음부터 (**Steer, Throttle**) 로 고정 — 이후 모든 단계(BC-RL)가 이 위에서 동작

초기 URDF 주행 테스트	현재 차량 주행 (PathFollower)
	

좌: box URDF 의 Genesis 주행 테스트 / 우: 현재 차량의 경로 추종 주행 — 빨간 선 = reference 경로, 노란 마커 = lookahead

1.3 물리 정합 ① — Ray-Wheel 충돌 구조

Genesis 의 `cylinder ↔ terrain 3D` collision 은 contact normal 불안정·heightfield 변환 손실·substep=50 부담의 한계 → 바퀴 collision 을 제거하고 **raycast hit point** 를 충돌 판정에 사용하는 ray-wheel 구조로 전환 (CARLA 방식에서 아이디어)

	기존 (cylinder↔mesh)	Ray-Wheel
충돌 계산	GJK/SDF penetration, contact 최대 5개/쌍	바퀴 중심 -z 방향 Ray 1개 ↔ BVH 교차
연산량	mesh vertex 비례 × substep 반복	mesh 100만 개도 $\log_2 \approx 20$ 스텝 — 바퀴 4개 = Ray 4개
접지 판정	penetration depth	<code>compression = tire_radius - hit_distance</code>

Genesis Lidar 센서로 구현 — attach 된 entity 자동 self-ignore 검증, $n_envs=2001$ 배치 지원 확인

- compression 에 **spring + 비대칭 damper** (압축 시 강하게 충격 흡수, 신장 시 약하게 반동 억제) 적용 → 서스펜션 역할 대체
- 연산이 가벼워 같은 예산으로 substep 증가·**2000 env 병렬** 가능 → MPPI-RL 의 대규모 롤아웃 기반



1.4 물리 정합 ② — Pacejka Anisotropic Tire Model

타이어는 단순 Coulomb friction 이 아니다 — 회전 방향(traction)과 횡방향(slip angle 변형)의 응답이 서로 달라, isotropic 마찰로는 재현 불가. 수직력은 **suspension**, 수평력은 **Pacejka** 로 분리한다.

$$F = D \cdot \sin\left(C \cdot \arctan\left(B \cdot s - E \cdot (B \cdot s - \arctan(B \cdot s))\right)\right)$$

요소	정의
종방향 slip κ	$(R\omega - v_{long})/ v_{long} $ — $\kappa>0$ 휠스핀, $\kappa<0$ 제동 슬립

요소	정의
횡방향 slip angle α	타이어가 향한 방향 vs 실제 이동 방향의 각
B, C, D, E	초기 강성 / 곡선 형상 / 피크 마찰 / 피크 이후 감쇠 — 종·횡 별도 파라미터셋

Pacejka 곡선	slip angle 정의
 Isotropic Tire Model (원형) Anisotropic Tire Model (타원형) → x : Forward (Longitudinal) ↑ y : Lateral	 Longitudinal velocity v_x Lateral velocity v_y α = lateral slip angle

- 두 채널은 수직항력 N 을 매개로 결합 — $D = \mu \cdot N$: 코너에서 차체가 쏠리면 외측 바퀴 N 증가 → 그립 한계 상승 → **weight transfer** 거동이 자연스럽게 재현
- raycast hit point + 차량 속도로 종/횡 slip 을 직접 계산하므로 anisotropic 모델 적용이 가능해짐 (입체 충돌은 isotropic Coulomb 만 지원)

1.5 정합 검증

- Blender ↔ Genesis 간 좌표계·timestep(1/48s)·지형 mesh·차량 파라미터(질량·서스펜션·마찰) 정렬
- 정합 평가: 동일 제어 입력에 대한 slope-kappa RMSE 로 검증

관련 문서: [25-10-14] genesis_car_urdf · [26-03-15] Sim2Sim Calibration · [26-05-02] ray_wheel · [26-05-07] pacejka_model

2. 골든 라벨 채굴 — MPPI on Terrain

2.1 MPPI 정의

"수많은 미래를 실행해보고, 그중 잘된 것들을 가중평균해서 지금 뭘 할지 정하는" sampling 기반 MPC.

1. 병렬 샘플링: 2048개의 '유령 차'가 동시에 미래 horizon 스텝을 주행
2. 룰아웃: 후보 제어 시퀀스를 실제 물리로 전개
3. 비용 계산: 각 샘플의 cost 합산
4. 가중평균 선택: temperature $\lambda = 0.01$ — 비용이 낮은 샘플에 가중치가 물리게
5. 업데이트: 최적 제어 (T, S) 한 스텝 적용 후 반복

- MPC 는 비선형 최적화를 CPU 에서 순차 해결 → 튜닝 비용 5~36시간. **GPU 병렬 MPPI 로 전환**
- 미분 불필요 — Genesis 물리가 blackbox 여도 "앞으로 굴러보기"만 되면 됨

2.2 Cost 설계


$$cost = \sum_h [w_{dist} \cdot dist + w_{heading}|\Delta\theta| + w_{vel}|\Delta v| + w_{pitch}|\Delta pitch| + w_{roll}|\Delta roll| + w_{rate}|\Delta u| + \dots]$$


가중치	값	역할
w_dist	6000	경로 이탈 ← 최우선
w_heading	4000	차가 향한 방향
w_vel	2500	속도 추종
w_pitch / w_roll	800 / 600	언덕·좌우 자세
w_rate	150	조작 부드러움
w_kappa / w_accel	50 / 1	곡률·가속 프로파일

cost 는 $w \cdot |\text{오차}|$ 형태 — 각 항의 단위와 평소 오차 크기가 달라, 실제 기여량은 $w \times \text{그 항의 평소 오차}$ 로 봐야 한다.
(방향 오차는 rad 라 작아서 가중치를 크게)

2.3 데이터 스케일링

시드 기반 heading perturbation 으로 하나의 terrain mesh 위에 경로를 무한 생성:





단일 terrain 위에 생성한 대량 경로 — 지형 물리를 고정하고 경로 다양성만 분리

- Claude MCP → Blender 로 s, t 를 직접 주입, 한국도로공사 규격 곡률·시케인·헤어핀 경로 생성
- **35개 시나리오** (p112 + p120~p153), 씬당 ~480 frames
- 마이닝 가속화: dual_scene 전환으로 1씬 33분 → **4분 (×8.2)**, 전면 재마이닝 19h → 2.5h

항목	값
병렬 룰아웃	2048 env × horizon
경로 유형	직진 / 커브 / 시케인 / 헤어핀
mean drift	0.01 ~ 0.36 m (경로별)

관련 문서: [26-02-22] MPP1 · [26-06-01] MPP1_onTerrain · [26-06-24] data

3. BC Mapper — 골든 라벨 지도학습

Behavior Cloning: 채굴된 golden (T, S) 를 정답 라벨로, Reference 공간의 움직임을 zero-shot 으로 모사하는 policy(ST Mapper)를 학습

3.1 Input State (31D)

그룹	Dim	피쳐	설계 의도
FeedBack	3	delta_v, delta_heading, cte	누적 오차 명시 → PID 의 오차 항을 신경망으로
Current State	4	v_long, kappa, pitch, roll	차량의 현재 물리 상태
FeedForward k	10	k_target[t+1..t+10]	미래 곡률 — 사전 조향 준비
FeedForward a	10	a_target[t+1..t+10]	미래 가속 — 사전 스톱틀 준비
Current FF	1	a_target	현재 스텝 FF 직접 참조
경향성 미분	3	dv_rate, pitch_rate, roll_rate	상태 변화 방향 — 관측 스파이크 흡수

핵심 설계 판단 두 가지:

1. **prev (S, T) 제거** — 이전 제어값을 입력하는 순간 copycat / data leakage 가 됨. 대신 **prev 5 frame** 의 평균 변화율 (미분 3D)로 경향성만 주입 — $dt(1/48)$ 가 작아 단일 프레임 미분은 노이즈이므로 5프레임 스무딩
2. **출력을 액션 청크로** — 1:1 프레임 학습은 MPPI 라벨의 프레임별 노이즈를 그대로 흡수한다. 출력을 $(T, S) \times 10$ 스텝 오버랩 청크(Tanh, [-1,1])로 바꿔 시퀀스 구조 안에서 평균화 → 자체 스무딩


3.2 학습 설정

- 좌우반전 증강(2배), 노이즈 주입(heading/cte/pitch/roll), StandardScaler 정규화
- trajectory 단위 train/val 분할 (temporal leakage 방지)
- Adam lr=5e-4, wd=1e-3 — early stop 제거, **300 epoch 전부 학습 후 best 만 저장** (선발은 val loss 가 아니라 페루프 CTE)

평가 기준 교훈: "다음 프레임을 잘 예측하는가"(val loss)와 "실제로 돌렸을 때 궤적을 잘 따라가는가"(closed loop)는 서로 다른 지표다. 주행은 시퀀스 롤아웃 — 모델의 출력이 다음 입력 분포를 바꾼다(covariate shift).

3.3 A/B 결과 (동일 26번)

지표	1스텝	액션 청크	청크+경향성
페루프 robust score	1.458	0.667 (-54%)	0.627 (-57%)
검증 26경로 평균 CTE	1.17 m	0.89 m	0.73 m (-38%)
학습 후반 안정성	ep10 후 붕괴	건강	건강



관련 문서: [26-07-07] multi-frame_mlp

4. Residual RL — Frozen BC + PPO

BC Mapper 의 경로 추종은 준수하나 곡률·고속 추종을 국소 교정하기 위해, 학습이 끝난 **BC Mapper** 를 **Freeze** 하고 그 위에 **잔차(residual) 정책**만 PPO 로 학습한다. 최종 행동 = BC 기본행동 + 잔차. → BC 의 전역 안정성을 보존하면서, RL 은 "얼마나 더/덜 밟고 꺾을지"의 **작은 보정**만 담당.

4.1 구조 정의

$$u = T_{BC} + \Delta u \quad S = S_{BC} + \Delta S$$

비대칭 잔차 cap: $\Delta u \in [-0.7, +0.3] \quad \Delta S \in [-0.25, +0.25]$

게이팅: $u \geq 0 \rightarrow \text{throttle}=u, \text{brake}=0$

$u < 0 \rightarrow \text{throttle}=0, \text{brake}=-u$

- 감속($-\Delta u$)의 폭을 넓게(0.7) — 안전측(감속) 보정을 더 허용
- **Brake 게이팅**으로 BC 가 다루지 않던 제동까지 행동 공간 확장 → **(S, T, B)** 완전 제어

구성	구조	역할
Actor	31 → 128 → 128 → 2 (ELU)	잔차 ($\Delta u, \Delta S$) 생성
Critic	(31 + Critic Obs 21) → 256 → 256 → 1	상태 가치 $V(s)$ 평가

- Critic Obs(21D): 실차에서 practical 하게 얻을 수 있는 신호만 — suspension 압축(4)·wheel omega(4)·IMU accel/gyro(4)·v_lat(1)·경로 preview 요약(7)·episode context(1). asymmetric actor-critic 관행(rsl_rl)

4.2 PPO 학습 설정

항목	값
병렬 env	512 (spawn 랜덤)
advantage	GAE
clip	0.2 (정책+가치 동시)
lr	3e-4, linear decay
minibatch / grad clip	4096 / 0.5
Curriculum	허용 최대 속도 점진 상승 (5 → 8 → 12 m/s)

Reward 설계 (1 episode = scene 전체 frame)

항	weight	목적
Progress (+)	+1.0	경로를 따라 전진 (프레임당 최대 전진량 제한)
CTE (-)	2.0	경로 이탈 감점 ← 최우선
Heading (-)	0.8	방향 불일치 감점
Velocity (-)	0.5	과속은 크게, 감속은 관대하게
Smooth/Res/Brake (-)	0.05~0.1	급조향·과대 보정·과도 제동 억제
종료 벌점	-10	cte >3m, 전복 시 종료

학습 구조 핵심: 경로 중간 랜덤 spawn 은 "모자이크"가 아니라 **초기조건** — settle 된 상태를 복원해 스폰하고 이하는 연속 물리 closed-loop. 어려운 구간(고속 코너)을 즉시 경험하게 해 학습 효율을 높이고, 오차 있는 초기조건에서 **복구 능력**을 학습한다(DAgger 와 유사 역할 — 단 expert 재질의 없이 reward 로 교정).

time 기반	position 기반

BC vs BC+RL

지표	BC	BC+RL	개선
횡오차 CTE (m)	0.232	0.059	-75%
heading 오차 (°)	1.74	0.67	-62%


- 신지표(arc-length) 기준 최종 |CTE| 는 **0.036 m** — §5 참조

관련 문서: [26-07-12] ResidualRL_on_BC · [26-07-12] PPO_terminology

5. 평가 지표 전환 — Path-Following 표준

기존 frame-indexed 지표는 time 추종에 유리하게 오염된다 — 조금이라도 뒤쳐지는 순간 feedback 오염 발생. "같은 프레임에 어디 있었는가"가 아니라 "경로 위 동일 위치를 얼마나 잘 따라갔는가" 로 전환.

- 선행 연구: Liniger et al., *Optimization-based autonomous racing of 1:43 scale RC cars* — progress 와 contouring error 를 분리해 다루는 contouring-control formulation
- **Primary**: arc-length grid($\Delta s=0.25m$) 기반 spatial |CTE|/|HE| — nearest-point 사영 (contouring error)
- **Feasibility**: $v^2|\kappa| > a_{safe}$ 위반율 — "곡률 대비 말이 되는 속도"의 직접 채점. reference 보다 감속해서 안정적으로 따라가면 벌점이 아님
- **Secondary**: point-to-point time / finish time ratio — pace 는 승패 미결정, 별도 표

tangential error	nearest-point CTE
	3.2.2. <i>Error measures.</i> In order to formulate the MPCC problem, error measures are needed that define the deviation of the car's current position X, Y from the desired reference point $X^{ref}(\theta), Y^{ref}(\theta)$. We use the same definitions as in [2] but give another derivation here. Let $\mathcal{P}: \mathbb{R}^2 \rightarrow [0, L]$ be a projection operator on the reference trajectory defined by $\mathcal{P}(X, Y) \triangleq \arg \min_{\theta} (X - X^{ref}(\theta))^2 + (Y - Y^{ref}(\theta))^2. \quad (8)$ For brevity, we define $\theta_P \triangleq \mathcal{P}(X, Y)$. The orthogonal distance of the car from the reference path is then given by the <i>contouring error</i> $e^c(X, Y, \theta_P) \triangleq \sin(\Phi(\theta_P))(X - X^{ref}(\theta_P)) - \cos(\Phi(\theta_P))(Y - Y^{ref}(\theta_P)), \quad (9)$

재측정 결과 (26실행 평균)

지표	pos	time
Primary CTE (m)	0.036	0.044
곡률존 CTE (m)	0.041	0.066
조향 effort (mrad/m)	194	257

새 지표로 재측정하니 pos 가 전 지표 우세 — 곡률존 -38%, 조향 -25%. 실제 viewer 관찰(선제 조향 없음)과 정량 지표가 비로소 일치했다.

관련 문서: [26-07-22] newMetric_disturb

6. 외란 복구 강화학습 — Single vs Switch Policy

RL 의 목표는 nominal 재현이 아니라 **교란이 있어도 경로 추종을 유지·복구**하는 것. 정상 추종 상태에서만 외란을 주입하고(이미 흐트러진 상태에 더하면 "복구"가 아니라 "누적 실패"를 학습), 강도는 커리큘럼으로 점진 상승, 일부 env 는 무외

란 baseline 유지.


6.1 외란 종류

외란	모사 상황	강도
spawn	출발 위치·자세·속도 오차	횡 $\pm 0.8\text{m}$, 방향 $\pm 8^\circ$, 속도 $\pm 20\%$
kick	옆바람·노면 단차 횡충격	학습 $0.5\sim 2.0$ / 시험 최대 5.0 m/s
brake	급제동·완전 정차	강제 인가 후 재출발
spin	스핀 유발 요레이트 충격	$\pm 1\sim 4\text{ rad/s}$

6.2 구성 1 — 단일 모델 RL_F: 주행 + 외란을 하나의 체크포인트로

주행 task 와 외란 복구를 하나의 모델(F)이 모두 하게 하여 성능을 측정해 보았다.

모델	구성	샘플	학습 시간 (RTX 4090)
RL_pos	무외란	~23M	$\approx 1.8\text{h}$
RL_F	RL_pos warm-start + 외란 학습	누적 ~288M	4.2h (누적 5.1h)



01_pos_looked_better.mp4


<https://github.com/user-attachments/assets/ed8d96e6-e9de-4cf7-8529-9fe317d670af>

• RL_F 는 코너 진입 시 조향 수정 빈도가 높고, 직선에서도 미세 조향 반복 — RL_pos 가 경로 중심을 더 안정적으로 유지 해석:

1. 학습선 일반 주행은 **RL_pos** 우위 (CTE 0.036 vs 0.050, 조향 194 vs 274)
2. 미학습선 일반 주행은 **F** 가 우위 (p161: 0.309 vs 0.087) — 외란학습이 정규화로 작동해 일반화를 얻고 학습선 정밀도를 소폭 내준 것
3. kick 급 외란은 동급(96%)이지만, **spin(4.0 rad/s)**은 양쪽 모두 실패 → OOD 대응 관측 자체가 없다

6.3 구성 2 — Switch Policy: 주행 정책 + Recovery Policy 분리

외란 대응을 주행 정책에 추가하는 대신, "경로 복귀"만 배우는 두 번째 policy 를 사용. 근거 — Recovery RL(RA-L 2021): task:recovery 를 한 보상으로 공동 최적화하면 균형이 무너진다 → 정책 분리 + 임계점 전환.




주행은 `RL_pos` 그대로, 대이탈 시 `Recovery Policy` 로 전환 — $dist < 3m$ 복귀 시 다시 인계

Recovery Policy 관측 12D — "나침반" 설계


설계 원칙: OOD 에서 발동되므로, 기존 RL 이 학습하지 않은 범위의 입력에서도 무너지지 않는 유계 관측만 사용

피쳐	정의	대이탈에서 살아있는 이유
<code>ang_bear</code>	$\sin/\cos(\text{경로 방위각})$	각도라 항상 유계 — "경로는 왼쪽 40°"가 1m든 30m든 같은 의미
이중 거리	$\tanh(d/5) + \tanh(d/20)$	근거리 미세조정 + 원거리 대세 — 한 스케일이면 5m 밖이 전부 ≈ 1 로 뭉개짐
<code>align</code>	$\sin/\cos(\text{경로 접선} - \text{heading})$	안착 직전 정렬용
<code>v_lat</code> / <code>v_long</code>	복귀 속도·속도상한 판단	오버슈트·지그재그 방지
<code>yaw_rate</code> / <code>pitch,roll</code>	회전·전복 임박 감지	스핀 직후 자세 안정화



학습 설계


항목	설계
구조	12 → 128 → 128 → 2 소형 MLP — actor 72 KB , 스위칭은 if 문 수준
episode	정상 스폰 → 즉시 물리 충격(횡속 0.5–8 m/s + yaw ± 1 –4 rad/s) → 복귀가 과제. 텔레포트 없음
판정	armed : 3m 이탈을 실제로 겪은 뒤 $d < 2.5m$ 를 12프레임 유지 — 스폰 직후 공짜 성공 차단
reward	접근 potential + 근접 정렬 + 속도상한 초과 벌점 + 저속 벌점(정차 함정 방지) + 조향 스무드
학습량	26씬 × 4096env × 128 × 250it $\approx$ 131M 샘플, $\approx 3.5h$



04_posVsV3.mp4

(<https://github.com/user-attachments/assets/75189ab4-97fc-4eab-b781-e001117439ad>)

- **kick**: 단일 모델 대비 보다 자연스러운 switching 복구



02_pos_fail_vs_recovery.mp4

<https://github.com/user-attachments/assets/ce8c5beb-758a-49ac-8693-8e7b0b865fe5>


- 미학습 썬 **spin**: pos 는 복구 실패, switching 은 복구 성공

6.4 구성 3 — 통합 단일 모델: 경로 방향 관측 + 보상 블렌딩

정량 평가 중, policy 분리 선행연구에 너무 초점이 맞춰져 있음을 깨달음 — 기존 F 에는 OOD 대비 관측 자체가 없었고, 테슬라도 단일모델 + 데이터로 강건성을 얻는 구조다. 관측을 포함해 재설계.

구성요소	설계
observation	31D → 36D — 복귀 방향 정보 5D 추가 (sin/cos(bearing), tanh(d/5), tanh(d/20), align)
reward	$r = w(d) \cdot r_{base} + (1 - w(d)) \cdot r_{rec}$ — 경로위/경로이탈 보상을 거리로 블렌딩
$w(d)$	$\exp(-\max(0, d - 1)/2)$ — smooth blending . 1m 이내 $w=1$ (기존 보상 보존), 멀어질수록 복구 보상 지배
학습량	26썬 × 4096env × 128 × 1000it ≈ 524M 샘플, 14.1h


4종 외란 복구 (학습썬) — 단일 모델로 성공



34_융합_kick5.0_p124_복구.mp4

<https://github.com/user-attachments/assets/ae20e932-2f87-4c4f-a373-52c26f00998f>


- kick 5.0 m/s → 완주 0.80배, cte 0.32



35_융합_brake1.0완전정차_p134_복구.mp4

<https://github.com/user-attachments/assets/6e6e8055-6f26-4440-9dd4-46aaa3720cea>

- 강제제동 → 완전 정차($v=0$) 후 재출발 → 완주 1.19배




36_융합_spin4.0_p120_복구.mp4

<https://github.com/user-attachments/assets/c6d19dc3-408a-497b-8eda-5b9b367424e9>

- spin 4.0 rad/s → 대이탈(17m급) 복구까지 단일 모델로 성공

미학습션 spin — 실패 사례



37_융합_spin4.0_p161미학습_실패.mp4

(<https://github.com/user-attachments/assets/ba043352-a086-43ee-99f8-c21b20704ed2>)

- spin 4.0 (p161 미학습) → DNF: 3m 까지 복구 후 **catch-up** 과속으로 재발산

실패 원인 — 재진입 상태 분석

	switch (pos ⇐ recovery)	통합 단일
재진입 속도	~3~5 m/s	8~10 m/s 상승 중 (catch-up 각인)
재진입 정렬	보장됨	무보장 — 45° 방위로 진입 시도
인계 후 base 상태	pos 의 학습 분포 안	3m 밖·고속 = 학습 분포 밖

- 스위치는 각 문제를 각각의 학습 도메인에서 다른 모델이 맡아 보상 충돌이 없는 반면, 단일 모델은 복구→정상 전환 시 보상 구조 혼란으로 불완전한 액션이 학습됨 → 보상 전환 구조 수정 후 재학습 중

6.5 전 구성 정량 비교

지표	RL_pos	RL_F	switch	통합 단일
clean 26번 CTE (m)	0.036	0.050	0.036	0.017
미학습 p161 clean CTE	0.309	0.087	0.309	0.315
kick 복구 24회	96%	96%	100%	100%
Spin 4.0 (학습씬)	2.01×	DNF	1.93×	2.11×
Spin 4.0 (미학습씬)	DNF	DNF	1.66×	DNF
배포 actor	82 KB	82 KB	154 KB	85 KB

- **switch** 가 유일하게 전 시험 완주 — 288M 샘플의 단일 모델이 못 한 복구를 **72KB 분리 정책**이 해결
- 통합 단일은 clean 정밀도 최고(0.017)-kick 100% — spin 일반화만 미해결

관련 문서: [26-07-29] disturb_switchpolicy

단계별 핵심 성과

단계	상태	핵심 결과
Sim2Sim 정합	완료	Blender ↔ Genesis ray-wheel 물리 정합 (48Hz)
골든 라벨 채굴	완료	35 시나리오 × 표준 지형, dual_scene ×8.2 가속
BC Mapper	완료	액션 청크 + 경향성 미분 — 페루프 -57%
Residual RL	완료	BC freeze + PPO, brake 추가 — CTE -75% (최종 CTE 0.036)
평가 지표	완료	Path-Following 표준 (arc-length CTE/HE + feasibility)
외란 강건화	진행 중	Switch Policy 전 시험 완주 / 통합 단일 재학습 중
Real2Sim	다음 단계	실측 궤적·지형의 시물 정합, 실환경 분포 라벨 재채굴
Sim2Real	최종 목표	학습 정책의 실차 전이